Classificação de Imagens de Gatos e Cães: um Estudo Comparativo de Descritores HOG/LBP, Classificadores Supervisionados e Comitês

Lucas Gabriel Castro Medeiros da Silva[1]

[1]Instituto Metrópole Digital – Universidade Federal do Rio Grande do Norte (UFRN)
Natal – RN – Brasil

lucas.gabriel.castro.083@ufrn.edu.br

Abstract. *This paper presents a comparative study of supervised classification techniques applied to a binary image classification problem (cats vs. dogs) from the Oxford-IIIT Pet Dataset. Feature extraction was performed with HOG and LBP descriptors, followed by PCA dimensionality reduction, producing 19 datasets. The twelve best datasets were selected via k-NN and used to evaluate four base classifiers (k-NN, Decision Tree, Naive Bayes, and MLP) and four classifier ensembles (Bagging, Random Forest, Voting, and Stacking). All results were assessed under 10-fold cross-validation and 70/30 holdout, using the weighted F1-score, and compared through Friedman and Nemenyi statistical tests.*

Resumo. *Este artigo apresenta um estudo comparativo de técnicas de classificação supervisionada aplicadas a um problema binário de classificação de imagens (gatos vs. cães) do Oxford-IIIT Pet Dataset. A extração de características foi realizada com os descritores HOG e LBP, seguida de redução de dimensionalidade por PCA, gerando 19 bases. As doze melhores bases foram selecionadas via k-NN e utilizadas para avaliar quatro classificadores base (k-NN, Árvore de Decisão, Naive Bayes e MLP) e quatro comitês de classificadores (Bagging, Random Forest, Voting e Stacking). Todos os resultados foram avaliados sob validação cruzada 10-fold e holdout 70/30, usando o F1-score ponderado, e comparados por meio dos testes estatísticos de Friedman e Nemenyi.*

1. Introdução

A classificação de imagens é um problema central em visão computacional, com aplicações que vão do diagnóstico médico ao reconhecimento de objetos. Neste trabalho, abordamos a tarefa de distinguir imagens de gatos e cães a partir de descritores clássicos de características, sem o uso de redes neurais convolucionais, com o objetivo de analisar comparativamente o comportamento das técnicas de aprendizado supervisionado estudadas ao longo da disciplina.

O fluxo experimental foi dividido em seis etapas encadeadas: (i) extração de características com HOG e LBP e redução de dimensionalidade com PCA; (ii) seleção das doze melhores bases via k-NN; (iii–v) avaliação dos quatro classificadores base (k-NN, Árvore de Decisão, Naive Bayes e MLP); e (vi) avaliação de quatro estruturas de comitês de classificadores. Por fim, todos os resultados foram submetidos a análise estatística por meio dos testes de Friedman e Nemenyi.

2. Referencial Teórico

HOG (Histogram of Oriented Gradients). Descritor que captura a distribuição local das direções dos gradientes de intensidade, eficaz para representar a forma e as bordas dos objetos.

LBP (Local Binary Pattern). Descritor de textura que codifica, para cada pixel, um padrão binário a partir da comparação com seus vizinhos em um dado raio, sendo robusto a variações monótonas de iluminação.

PCA (Principal Component Analysis). Técnica de redução de dimensionalidade que projeta os dados em componentes que preservam um percentual da variância explicada, reduzindo redundância entre atributos.

Classificadores supervisionados. Foram utilizados k-NN (baseado em distância), Árvore de Decisão (particionamento recursivo do espaço de atributos), Naive Bayes (probabilístico, assumindo independência condicional) e MLP (rede neural com camadas densas).

Comitês de classificadores. Estruturas que combinam múltiplos modelos para melhorar a robustez: Bagging e Random Forest (homogêneos, baseados em reamostragem) e Voting e Stacking (heterogêneos, combinando técnicas distintas).

Testes estatísticos. O teste de Friedman verifica se há diferença estatística entre múltiplos modelos avaliados sobre as mesmas bases; quando a hipótese nula é rejeitada ($p < 0{,}05$), o teste post-hoc de Nemenyi identifica quais pares de modelos diferem entre si.

3. Trabalhos Relacionados

A classificação de imagens de animais de estimação tem como referência o trabalho de Parkhi et al. (2012), que introduziu o Oxford-IIIT Pet Dataset e explorou descritores de forma e aparência para o reconhecimento de raças. Os descritores empregados neste estudo derivam de trabalhos seminais: o HOG foi proposto por Dalal e Triggs (2005) para detecção de pedestres, mostrando-se eficaz na captura de informação de gradiente e borda; o LBP, formalizado por Ojala et al. (2002), tornou-se um padrão para análise de textura por sua robustez a variações de iluminação. No âmbito da comparação estatística de classificadores, este trabalho segue a metodologia consagrada por Demšar (2006), que recomenda o teste de Friedman seguido do post-hoc de Nemenyi para avaliar múltiplos modelos sobre múltiplas bases. Diferentemente de abordagens baseadas em redes convolucionais, este estudo concentra-se em descritores clássicos combinados a classificadores tradicionais e comitês, permitindo uma análise controlada do efeito do descritor e da estrutura de combinação sobre o desempenho.

4. Metodologia dos Experimentos

4.1. Descrição do Problema e Base de Dados

O conjunto de imagens provém do Oxford-IIIT Pet Dataset. As raças sorteadas foram Abyssinian e Siamese (gatos) e Boxer e Wheaten Terrier (cães), configurando um problema de classificação binária balanceado (`cat` vs. `dog`). As imagens foram redimensionadas para 256×256 e 128×128 pixels antes da extração de características.

4.2. Pré-processamento e Extração de Características

Aplicou-se o extrator HOG (`orientations`=9, `cells_per_block`=$(2, 2)$) variando o tamanho da célula, e o extrator LBP (método `uniform`, escala de cinza) variando o raio. Sobre as bases HOG, aplicou-se PCA (com `StandardScaler` + `whiten`) preservando 75% e 90% da variância. Ao final, foram geradas **19 bases**: 6 HOG, 3 LBP e 10 HOG+PCA. A Tabela 1 resume as características das bases.

Tabela 1. Resumo das bases geradas (exemplos por descritor).

Descritor	Configuração	Atributos	Base
HOG	128×128, célula 32×32	324	HOG_128_32x32
HOG	256×256, célula 32×32	1.764	HOG_256_32x32
HOG	128×128, célula 8×8	8.100	HOG_128_8x8
LBP	raio 3	26	LBP_256_3R
LBP	raio 6	50	LBP_256_6R
LBP	raio 12	98	LBP_256_12R
HOG+PCA	75% sobre HOG_256_32x32	96	PCA_075_HOG_256_32x32
HOG+PCA	90% sobre HOG_128_16x16	229	PCA_090_HOG_128_16x16

4.3. Seleção das Bases (k-NN)

Para selecionar as doze melhores bases, executou-se o classificador k-NN (métrica euclidiana, k variando de 1 a 10) sob 10-fold CV e holdout 70/30, usando o F1-score como métrica. As doze bases com melhor F1-score médio foram selecionadas e utilizadas em todos os experimentos subsequentes, conforme a Tabela 2.

Tabela 2. As doze melhores bases selecionadas pelo k-NN (F1-score médio).

#	Base	F1 médio
1	LBP_256_6R	0,6430
2	LBP_256_12R	0,6289
3	LBP_256_3R	0,6281
4	HOG_128_32x32	0,6182
5	HOG_128_16x16	0,4426
6	HOG_256_32x32	0,4255
7	HOG_256_32x32 PCA-75%	0,3977
8	HOG_128_16x16 PCA-75%	0,3936
9	HOG_128_8x8	0,3781
10	HOG_128_16x16 PCA-90%	0,3675
11	HOG_128_8x8 PCA-90%	0,3565
12	HOG_256_32x32 PCA-90%	0,3556

4.4. Classificadores Base

Cada um dos quatro classificadores foi avaliado sobre as doze bases, sob 10-fold CV (`shuffle=True`, `random_state=1`) e holdout 70/30 (`random_state=19`), com F1-score ponderado.

k-NN. Variação de k de 1 a 10, métrica euclidiana.

Árvore de Decisão. GridSearch com `criterion` $\in$ {gini, entropy, log_loss} e `max_depth` $\in \{2,\ldots,15\}$, totalizando 42 combinações; seleção das 10 melhores configurações por 10-fold CV na melhor base, com `random_state=42`.

Naive Bayes. Comparação de três variantes da família: GaussianNB, MultinomialNB e ComplementNB. Para as variantes que exigem atributos não-negativos, aplicou-se `MinMaxScaler` dentro de um `Pipeline` para evitar vazamento de dados entre folds.

MLP. GridSearch com 1.280 combinações (`hidden_layer_sizes`, `activation`, `solver`, `learning_rate_init`, `max_iter`); seleção das 10 melhores configurações por holdout 70/30 na melhor base (LBP_256_6R), reaplicadas às doze bases.

4.5. Comitês de Classificadores

Bagging. `BaggingClassifier` com `n_estimators` $\in \{10,15,20\}$, variando o estimador base entre k-NN, DT, NB e MLP (12 configurações).

Random Forest. `criterion` $\in$ {gini, entropy} e `n_estimators` $\in \{10,20,30,100\}$, demais parâmetros no padrão (8 configurações).

Stacking e Voting. Comitês heterogêneos com pools de 5, 10, 15 e 20 classificadores base (MLP, k-NN, DT e NB), com `LogisticRegression` como meta-classificador no Stacking e `voting='soft'` no Voting.

4.6. Análise Estatística

Para cada técnica, construiu-se uma matriz [12 bases $\times$ N configurações] com o F1-score médio de validação cruzada, aplicando o teste de Friedman. Quando $p < 0{,}05$, aplicou-se o post-hoc de Nemenyi com diagrama de diferença crítica. Caso contrário, registrou-se a ausência de diferença estatística e a escolha do melhor modelo por complexidade $\times$ desempenho médio. As comparações realizadas foram: (i) entre as melhores técnicas base; (ii) entre os melhores comitês; e (iii) entre o melhor classificador individual e o melhor comitê (teste de Wilcoxon pareado, por se tratar de dois grupos).

5. Resultados Experimentais

5.1. Classificadores Base

A Tabela 3 resume o desempenho médio (sobre as doze bases) dos melhores resultados de cada classificador base. O MLP e o Naive Bayes apresentaram os melhores desempenhos médios (F1 ponderado $\approx 0{,}71$), seguidos pela Árvore de Decisão ($0{,}6630$) e pelo k-NN. Ressalta-se que o k-NN foi avaliado com F1 *macro* (no experimento de seleção das bases), enquanto os demais usam F1 *ponderado*; por isso seus valores devem ser interpretados como referência relativa, e não em comparação direta de magnitude. Observou-se uma inversão de comportamento em relação ao k-NN: enquanto este favoreceu as bases LBP (de baixa dimensionalidade), NB e MLP tiveram melhor desempenho nas bases HOG e HOG+PCA de maior dimensionalidade. A Árvore de Decisão, por particionar o espaço de atributos, mostrou-se estável porém menos competitiva, com a melhor configuração usando `criterion=gini` e `max_depth=4`.

Tabela 3. Desempenho médio dos classificadores base (F1-score ponderado).

Classificador	Melhor config.	F1 médio (12 bases)
Naive Bayes (GaussianNB)	—	0,7119
MLP	Conf. 08	0,7122
Árvore de Decisão	gini, max_depth=4	0,6630
k-NN*	—	0,5235

* O k-NN foi avaliado com F1-score *macro* no experimento de seleção de bases; os demais classificadores usam F1-score *ponderado*. Os valores do k-NN servem de referência relativa.

5.2. Comitês de Classificadores

A Tabela 4 resume o melhor modelo de cada comitê, selecionado por análise estatística. Para cada estrutura de comitê, aplicou-se o teste de Friedman *entre suas próprias configurações* (as 12 do Bagging, 8 do Random Forest, e 4 do Stacking e do Voting), conforme exigido na avaliação por técnica. O Random Forest com `criterion=entropy` e 100 estimadores apresentou o melhor desempenho médio entre todos os comitês. No Stacking, o teste de Friedman não detectou diferença estatística entre os tamanhos de pool ($p = 0{,}296$), de modo que a seleção recaiu sobre o critério de complexidade $\times$ desempenho.

Tabela 4. Melhor configuração de cada comitê (F1-score médio de CV) e resultado do teste de Friedman.

Comitê	Melhor config.	F1 médio	Friedman
Bagging	MLP (15)	0,7019	$p = 1{,}0 \times 10^{-7}$ (dif.)
Random Forest	Entropy (100)	0,7488	$p = 2{,}6 \times 10^{-12}$ (dif.)
Stacking	Classificadores (20)	0,7404	$p = 0{,}296$ (sem dif.)
Voting	Classificadores (15)	0,7182	$p = 1{,}96 \times 10^{-4}$ (dif.)

5.3. Análise Estatística Final

Entre as técnicas base. O teste de Friedman indicou diferença estatística ($p = 3{,}2 \times 10^{-5} < 0{,}05$). O post-hoc de Nemenyi colocou o **MLP** no melhor rank médio (F1 $= 0{,}7122$), seguido por NB, DT e k-NN; MLP e NB superaram o k-NN com significância estatística.

Entre os comitês. O teste de Friedman também indicou diferença ($p = 5{,}6 \times 10^{-4} < 0{,}05$), com o **Random Forest (Entropy, 100 árvores)** no melhor rank médio (F1 $= 0{,}7488$), seguido pelo Stacking.

Melhor técnica base vs. melhor comitê. Comparando o MLP (melhor classificador individual, F1 $= 0{,}7122$) com o Random Forest (melhor comitê, F1 $= 0{,}7488$) por meio do teste de Wilcoxon pareado, obteve-se $p = 6{,}8 \times 10^{-3} < 0{,}05$. Portanto, **o comitê apresentou melhora estatisticamente significativa** sobre o melhor classificador individual, confirmando o benefício da combinação de modelos para este problema. A Tabela 5 consolida esses resultados.

Tabela 5. Resumo da análise estatística final.

Categoria	Melhor modelo	F1 médio	Teste (p)
Técnica base	MLP	0,7122	Friedman ($3{,}2 \times 10^{-5}$)
Comitê	RF Entropy(100)	0,7488	Friedman ($5{,}6 \times 10^{-4}$)
Base vs. Comitê	RF Entropy(100)	0,7488	Wilcoxon ($6{,}8 \times 10^{-3}$)

6. Conclusão

Este trabalho comparou descritores de características, classificadores supervisionados e comitês na classificação binária de imagens de gatos e cães. Os principais achados foram: (i) a escolha do descritor interage fortemente com o classificador — o k-NN favoreceu LBP de baixa dimensão, enquanto NB, MLP e os comitês favoreceram HOG/HOG+PCA de maior dimensão; (ii) entre os classificadores base, o MLP obteve o melhor rank, com diferença estatisticamente significativa sobre o k-NN; (iii) entre os comitês, o Random Forest obteve o melhor desempenho médio, com diferença estatisticamente significativa; e (iv) o melhor comitê (Random Forest) superou o melhor classificador individual (MLP) com significância estatística ($p = 6{,}8 \times 10^{-3}$, Wilcoxon), confirmando o ganho obtido pela combinação de modelos. O Stacking, embora competitivo, não apresentou diferença estatística entre suas configurações de tamanho.

6.1. Dificuldades e Sugestões de Melhoria

O principal desafio foi o custo computacional dos comitês baseados em MLP e do Stacking, mitigado com paralelização e checkpoints. Como melhorias, sugere-se: normalização sistemática das features para estabilizar o MLP em bases de alta dimensão (onde houve colapso de convergência); exploração de mais percentuais de variância no PCA; e a inclusão de uma métrica explícita de diversidade dos comitês para aprofundar a análise diversidade $\times$ desempenho.

Referências

- Parkhi, O. M. et al. (2012). *Cats and Dogs*. CVPR.
- Dalal, N.; Triggs, B. (2005). *Histograms of Oriented Gradients for Human Detection*. CVPR.
- Ojala, T. et al. (2002). *Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns*. IEEE TPAMI.
- Demšar, J. (2006). *Statistical Comparisons of Classifiers over Multiple Data Sets*. JMLR.
- Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR.